

WS 2023/24

FB Wirtschaftswissenschaften

Modul Künstliche Intelligenz in der öffentlichen Verwaltung

Hausarbeit zum Thema

**Wann kann hybride Intelligenz entstehen? Eine prozess-technische Betrachtung auf Basis eines Algorithmus zur Ableitung der nordrhein-westfälischen Landbedeckung mit Fernerkundungsdaten**

Dozent: Prof. Dr. Matthias Söllner

Datum der Abgabe: 29.03.2024

Wörter: 3740

Verfasser: Benjamin Bleske

Studiengruppe: MPA 53B NRW

Matrikelnummer: 36104066

# INHALTSVERZEICHNIS

Abkürzungsverzeichnis .....	iii
Abbildungsverzeichnis .....	iv
1 Einleitung.....	1
2 Künstliche und Hybride Intelligenz.....	2
2.1 Intelligenz .....	2
2.2 Machine Learning.....	2
2.3 Deep Learning .....	3
2.4 Hybride Intelligenz.....	5
3 Soll/Ist Prozess .....	7
3.1 Cop4ALL.....	7
3.2 Ist Prozess .....	13
3.2.1 Funktionsweise und Ergebniserzeugung .....	13
3.2.2 Verfahren .....	15
3.3 Soll Prozess.....	18
4 Fazit .....	21
5 Quellenverzeichnis .....	24
Eidesstattliche Erklärung & Einwilligungserklärung Nutzung von Plagiatssoftware.....	28

## **Abkürzungsverzeichnis**

ALKIS .....	amtliches Liegenschaftskatasterinformationssystem
ATKIS .....	amtliches topografisch-kartographisches Informationssystem
KI .....	künstliche Intelligenz
nDOM .....	normalisiertes digitales Oberflächenmodell
NN .....	neuronales Netz
DOP .....	digitales Orthophoto
DGM .....	digitales Geländemodell
DOM .....	digitales Oberflächenmodell
NDVI .....	normalized differenced vegetation index
RNN .....	recurrent neuronal network
CNN .....	convolutional neuronal network
HI .....	hybride Intelligenz
AdV .....	
Arbeitsgemeinschaft der Vermessungsverwaltungen der Länder der Bundesrepublik Deutschland	
ML .....	maschinelles Lernen
DL .....	deep learning
RL .....	reinforced learning
UL .....	unsupervised learning
SL .....	supervised learning
SE .....	sozio-technisches Ensemble

## **Abbildungsverzeichnis**

Abb. 1: Skizzenhafte Darstellung NN.....	4
Abb. 2: Segmentiertes Lieblingstier .....	5
Abb. 3: komplementäre Stärken.....	6
Abb. 4: Taxonomie eines HI Prozesses .....	6
Abb. 5: ALKIS Ausschnitt Sensenfeld, Bottrop .....	7
Abb. 5: ATKIS digitale topographische Karte Ausschnitt Sensenfeld, Bottrop.....	8
Abb. 7: DOP NRW Maßstab 1:870000 .....	9
Abb. 8: DOP Ausschnitt Sensenfeld, Bottrop Maßstab 1:1700 .....	10
Abb. 9: Sentinel-2 Bild Ausschnitt Sensenfeld, Bottrop .....	10
Abb. 10: Kombination unterschiedlicher multispektralen Bänder .....	11
Abb. 11: 13 Multispektrale Bänder von Sentinel 2 .....	11
Abb. 12: Sentinel Bild NDVI Ausschnitt Sensenfeld (im roten Kreis), Bottrop .....	12
Abb. 13: Cop4ALL Landbedeckung Sensenfeld, Bottrop .....	13
Abb. 14: Vergleich zwischen Cop4ALL und DOP Ausschnitt Sensenfeld, Bottrop .....	14
Abb. 15: Sentinel-2 Bild Reitplatz (im lila Kreis) Ausschnitt Sensenfeld, Bottrop .....	14
Abb. 16: Rote Punkte = versiegelte Flächen .....	15
Abb. 17: Verzweigte DL-Architektur .....	16
Abb. 18: ALKIS Veränderungshinweis .....	17
Abb. 19: 2D Cop4ALL vs. 3D Real Mesh Ausschnitt Sensenfeld, Bottrop .....	18
Abb. 20: 2D Cop4ALL vs. 3D Real Mesh Ausschnitt Legrandalle, Essen .....	20
Abb. 21: Prozess ohne HI .....	21
Abb. 22: Prozess mit HI .....	22
Abb. 23: Taxonomie-HI .....	23

## 1 Einleitung

Die Arbeitsgemeinschaft der Vermessungsverwaltungen der Länder der Bundesrepublik Deutschland (AdV) beschloss 2018 ihre landschafts- und liegenschaftsbezogenen Geodaten anlässlich immer differenzierter werdenden Nutzeranforderungen in die Basiskomponenten Landbedeckung und Landnutzung einzuteilen (Lucas et al. 2020). Auf europäischer Ebene war die Einteilung der Geodaten in Landnutzung und Landbedeckung bereits vollzogen (Sandmann et al. 2022: 299ff.). Gemeinsam mit dem Beschluss der AdV und einem hohen Interesse, Satellitenbilder in die Geodateninfrastruktur des Landes NRW zu integrieren, sowie in die 53 ansässigen Infrastrukturen der Katasterbehörden, resultierte in der Entwicklung des Fernerkundungsverfahrens Cop4ALL NRW (ebd.).

Das Verfahren nutzt die freiverfügbaren Satellitenbilder des Copernicus-Programms, in Kombination mit den zur Verfügung stehenden, geometrisch hochauflösten Bildern aus jährlich stattfindenden Luftbildbefliegungen. Mit Fachdaten zur Validierung und verschiedener Verfahren des maschinellen Lernens (ML) wird eine Landbedeckungsklassifizierung für NRW abgeleitet (ebd.). Das Ergebnis des Verfahrens liefert die Einteilung in eine Landbedeckungsklasse pro Pixel eines Satellitenbildes. Demnach wird zu einer versiegelten Stelle auf einem Grundstück die Klassifizierung zur Objektart LB\_Tiefbau vorgenommen. Diese einmalige Klassifizierung muss künftig aktuell gehalten werden, denn es kann sein, dass die betreffende Stelle in Zukunft entsiegelt wird und die ehemals richtige Klassifizierung sodann nicht mehr stimmt (ebd.).

Dazu werden die Landbedeckungsklassifizierungen von zeitlich verschiedenen Verfahrenseinsätzen miteinander verglichen, um die Stellen in den Bildern zu erkennen, die sich laut der Landbedeckungsklassifizierung verändert haben (ebd.: 307f.). Mithilfe dieser Hinweise lassen sich bestimmte Datenbestände automatisch fortführen.

95% der sogenannten Veränderungshinweise erbrachten 2022, sofern sie erzeugt wurden, eine Eignung zur automatischen Fortführung der Datenbestände. Allerdings wurden nur rund 10% der tatsächlichen Änderungen überhaupt detektiert (ebd.).

Hierbei drängt sich die Frage auf, ob und wann ein „[...] sozio-technisches Ensemble [...]“ (SE) (Dellermann et al. 2019a: 640) aus menschlicher und maschineller Intelligenz zu Hybrider Intelligenz (HI) werden kann, die die gegenwärtigen Ausschläge zu Gunsten eines verbesserten Gesamtergebnisses austariert.

---

## 2 Künstliche und Hybride Intelligenz

### 2.1 Intelligenz

Die Definition von Intelligenz hängt vom Kontext und von der Disziplin ab, indem sie eingebettet ist.

Eine Entität verhält sich intelligent, sofern sie die Kapazität hat, die physische Welt zu begreifen, sich an Vergangenes mehr als nur kurzfristig zu erinnern, Sachverhalte logisch zu durchdenken und Tätigkeiten, die auf zukünftiges Handeln ausgerichtet sind, zu planen (Fridman/Lecun 2024). Demnach kann Intelligenz die Fähigkeit darstellen, komplizierte Ziele, durch die Ausführung von effektiven Handlungen innerhalb eines Systems, zu erreichen, die von einem sich anpassenden, logischen Denkvermögen geplant worden sind (Dellermann et al. 2019a: 637ff.).

Menschliche Intelligenz sticht hierbei durch die universale Fähigkeit hervor, sich an manigfaltige, sich ändernde Umweltbedingungen anzupassen, indem Erfahrungen aus vergangenem Handeln auf die neue Situation angewendet werden (Ertel 2021: 3).

Die Definition von Künstlicher Intelligenz (KI) ist auf Grund der universalen Spannbreite des Intelligenzbegriffs vielschichtig (Buxmann/Schmidt 2021: 6). Zumindest besteht Einigkeit darüber, dass es sich um ein Teilgebiet der Informatik handelt, das die Absicht verfolgt, informationstechnische Systeme zu erforschen und zu entwickeln (ebd.; Franklin/Graesser 1997: 21ff.), damit diese selbstständig Probleme lösen können (Carbonell et al. 1983: 3ff.) und zwar besser als es momentan Menschen könnten (Rich 1985: 117; Rich 1983). Damit wird teilweise der Versuch angestrengt, mangelnde menschliche Fähigkeiten, oder Tätigkeiten, die einen unverhältnismäßig hohen menschlichen Ressourcenaufwand erzeugen würden, auf die Maschine auszulagern.

Hierbei entsteht auch die langfristige Absicht, alle stattfindenden Vorgänge im menschlichen Gehirn abzubilden und diese zu imitieren (Buxmann/Schmidt 2021: 6).

### 2.2 Machine Learning

Mit ML ist die Fähigkeit einer Maschine oder einer Software bzw. einem System gemeint, Aufgaben zu bewältigen, indem sie auf ihren Erfahrungsschatz zurückgreifen (ebd.: 9ff.; Mitchell 1997: 2f.). Dabei entsteht der Erfahrungsschatz mithilfe der Trainingsdaten, die ein

System vorher erhalten hat (ebd.). Das führt dazu, dass Softwareentwickler das eigene Wissen nicht mehr explizieren und codieren müssen: anstatt einer Maschine oder einer Software beizubringen, wie sich der Phänotyp einer Katze von dem eines Hundes unterscheidet, weil man wissen möchte, welches Tier sich auf einem Foto befindet, wird dem jeweiligen System eine schiere Menge von Katzen und Hunden gezeigt, anhand derer sich der Erfahrungsschatz des Systems aufbauen kann (Buxmann/Schmidt 2021: 9f.). Das System ist sodann in der Lage, selbstständig zu erkennen, welche phänotypischen Ausprägungen das jeweilige Tier hat, um so eine Entscheidung zwischen Hund und Katze zu treffen.

Bei dieser Art des ML handelt es sich um unsupervised learning (UL). Das sogenannte Lernen ohne Lehrer versucht dabei, Muster in Daten zu erkennen und diese Muster in entsprechende Kategorien einzuteilen (ebd.: 11).

Wenn das System die Unterschiede nicht allein erkennen muss, da es die Information, auf welchem Bild sich welches Tier befindet, schon hat, da diese abwechselnd mit dem Begriff Hund oder Katze Bilder beschriftet sind, handelt es sich um supervised learning (SL), dem Lernen mit einem Lehrer. Hierbei werden Daten explizit beschriftet (ebd.).

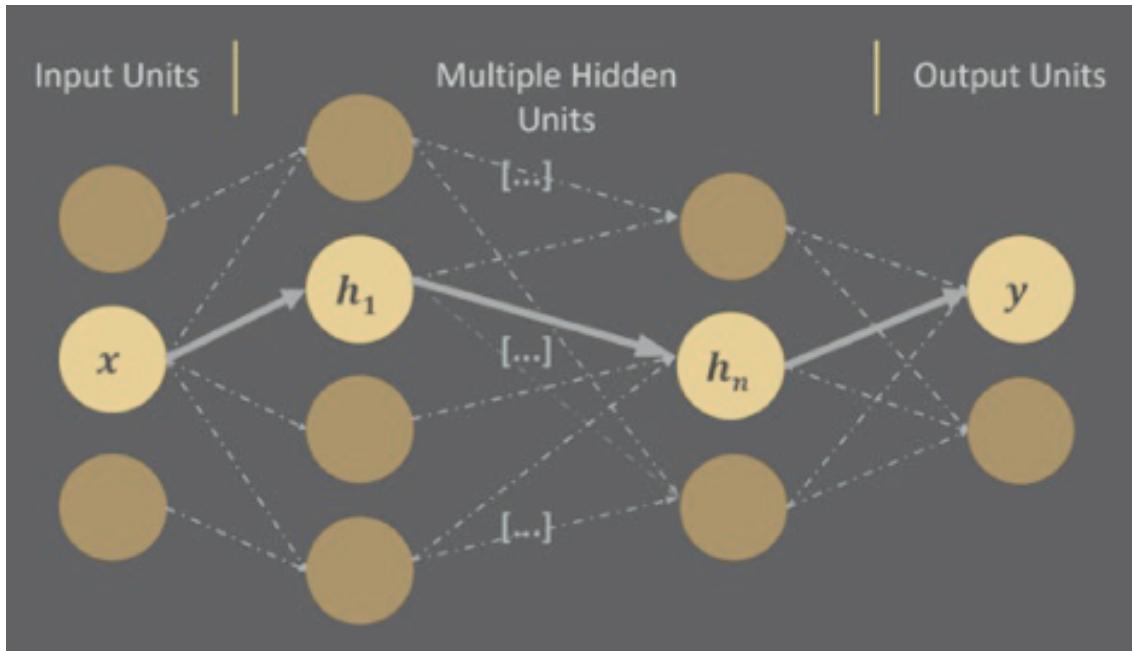
Wenn das System nur ab und zu die Information erhält, ob es sich bei der Entscheidung zwischen einem Hund und einer Katze für die richtige Gattungen entschieden hat, aber immer dann, wenn es die Information erhält, ebenfalls eine Belohnung erhält, handelt es sich um reinforced learning (RL), dem verstärkten Lernen (ebd.: 11ff.). Dabei ist das eigentliche Ziel, eine mathematische Funktion zu beeinflussen indem bei richtigen Entscheidungen additive Zahlen das Ergebnis der Funktion erhöhen, während es bei falschen Entscheidungen bestraft bzw. verringert wird. Das führt langfristig dazu, die strategisch sinnvollste Entscheidung zu treffen, um das Ergebnis der Funktion maximal durch die höchste additive Zahl zu erhöhen (ebd.). Hierbei ist das Beispiel zwischen Tieren auf Bildern eher ungeeignet. Das verstärkte Lernen entfaltet die größte Nützlichkeit bei der Berücksichtigung und Abwägung zwischen verschiedenen Entscheidungswegen, wie z.B. bei einem Schachspielzug (ebd.).

### 2.3 Deep Learning

Im Vergleich zum klassischen RL, UL und SL geht das Deep Learning (DL) einen Schritt weiter: mit Hilfe von künstlichen neuronalen Netzen (NN) wird versucht, das menschliche Gehirn zu simulieren (ebd.: 14ff.). Ein NN besteht dabei aus einer bestimmten Anzahl an verbundenen Neuronen durch Synapsen. Dabei gibt es drei Typen von Neuronen (ebd.): die

Input-, Hidden- und die Output-Units (Goodfellow et al. 2016: 167ff., 177ff., 187ff.; Rey/Beck 2018: 3). Input-Units repräsentieren Reize aus der Außenwelt, wie z.B. Pixel eines Satellitenbildes. Output-Units repräsentieren die Ausgangsdaten, wie z.B. die Klassifikation eines Tieres auf einem Bild zur Gattung Hund, oder die Einstufung in eine Landbedeckungsklasse. Hidden-Units bauen die Brücke zwischen beiden neuronalen Typen und tragen eine interne Repräsentation der Außenwelt inne. Dabei können mehrere Schichten von Hidden-Units durchlaufen werden (ebd.).

*Abbildung 1: Skizzenhafte Darstellung NN*



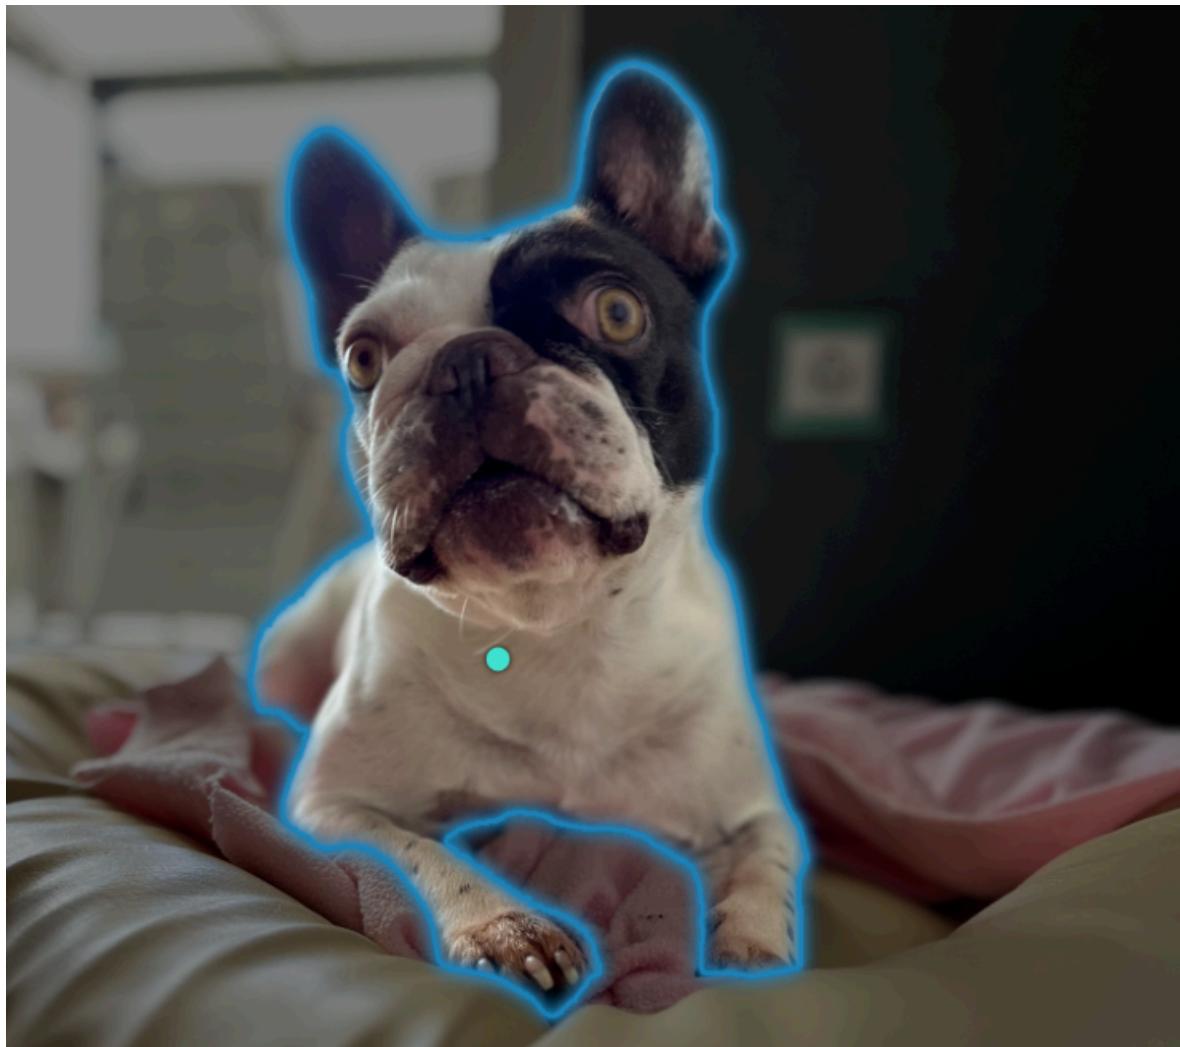
Quelle: Buxmann/Schmidt 2021: 15.

Die einzelnen Neuronen sind über Synapsen miteinander verbunden, an denen Gewichts-Faktoren hängen. Sofern eine Information über eine Synapse zum nächsten Neuron bzw. zur nächsten Unit transportiert wird, wird dieses unweigerlich mit dem festen Gewicht-Faktor, der mit der Synapse verbandelt ist, multipliziert. Dabei stellt der Gewichts-Faktor einer Synapse das gesamte erlernte Wissen eines NN dar (Buxmann/Schmidt 2021: 14f.).

Je nach Aufgabe oder Prozessschritt, für den das NN antrainiertes Wissen anwenden soll, tragen die Synapsen andere Gewichte. Bei der Entscheidung zwischen der Erkennung eines Hundes oder einer Katze auf einem Bild müssen z.B. erst die Kanten der zu erkennenden Entität, die auf den Pixeln des Bildes abgebildet sind, detektiert und dann vom Rest des Bildes getrennt werden. Daraufhin schließen sich verschiedene andere Prozesse mit anderen

Gewichts-Faktoren an. Um diese Gewichte zu identifizieren, wird die Backpropagation-Methode angewendet. Dabei handelt es sich im Wesentlichen um die Zurückrechnung eines falschen Ergebnisses, verbunden mit einer iterativen Anpassung der jeweiligen Gewichte, die zum falschen Ergebnis geführt haben (Buxmann/Schmidt 2021: 16).

*Abbildung 2: Segmentiertes Lieblingstier*



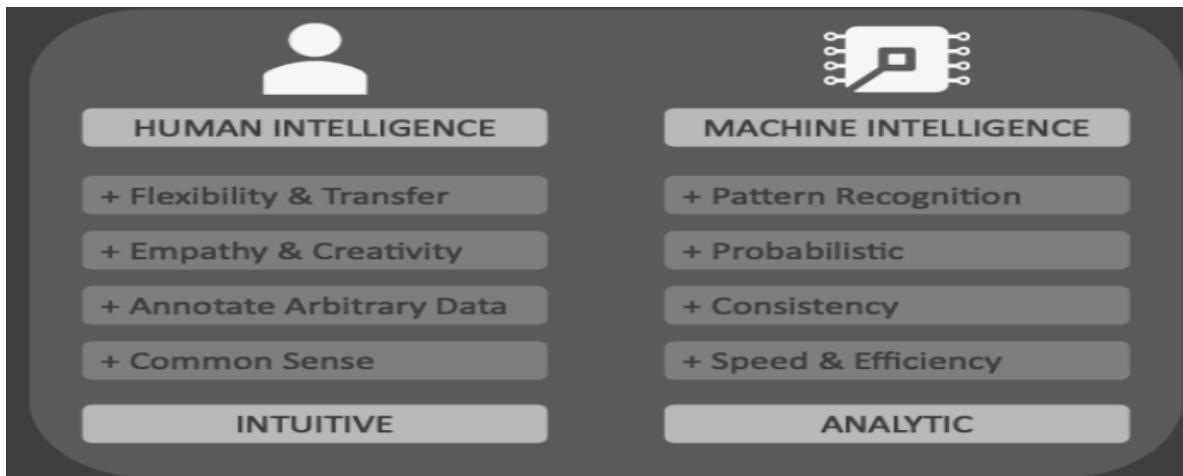
Quelle: eigene Abbildung erzeugt mit SAM (2023).

## 2.4 Hybride Intelligenz

HI verfolgt das Ziel, die komplementären Fähigkeiten der menschlichen und künstlichen Intelligenz in einem SE zu vereinen, um damit kontinuierlich die bestmöglichen Entscheidungen herbeizuführen (Dellermann et al. 2019b: 275ff.). Systeme mit HI haben sodann die Möglichkeit, komplexe Ziele durch die Vereinigung der heterogenen Intelligenzen zu erzeugen, die ohne die Vereinigung nicht möglich gewesen wären. Dabei steht das Verständnis vom kontinuierlichen Lernen, den überlegenen Resultaten und dem zusammenhängenden

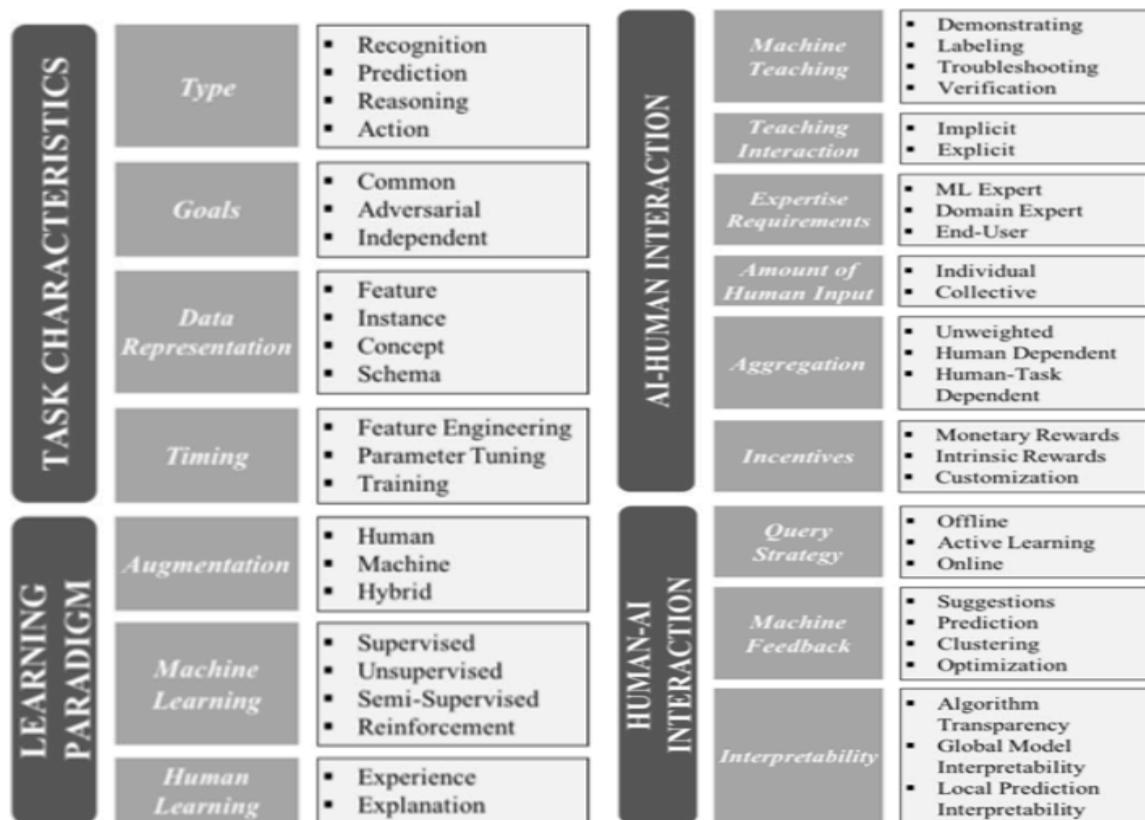
Arbeiten im Zentrum: erst dann, wenn Resultate erreicht werden, die ohne das Zutun der anderen Partei nicht möglich gewesen wäre, die jeweiligen Arbeiten voneinander abhängig sind und das SE kontinuierlich lernt, sowie beide Parteien für sich, handelt es sich um HI. Dabei bringt jede Partei komplementäre Fähigkeiten in das System ein.

Abbildung 3: Komplementäre Stärken



Quelle: Dellermann et al. 2019a: 640.

Abbildung 4: Taxonomie eines HI Prozesses



Quelle: Dellermann et al. 2019b: 278.

Taxonomisch betrachtet haben HI-gestützte Anwendungen regelmäßig Auswirkungen in vier Meta-Dimensionen, 16 Sub-Dimensionen mit insgesamt 50 Kategorien aus Abbildung 3. Sind diese Punkte im Konzept des Prozesses gegeben, liegt eine hohe Wahrscheinlichkeit für einen HI gestützten Prozess vor (ebd.: 278, 281).

### 3 Soll/Ist Prozess

#### 3.1 Cop4ALL

Der zu betrachtende Prozess Cop4ALL NRW wurde 2019 vom nordrhein-westfälischen Innenministerium in Auftrag gegeben (Sandmann et al. 2022: 300). Ziel von Cop4ALL NRW ist die Nutzung von Fernerkundungsdaten aus dem Copernicus Programm, aktuellen digitalen Orthophotos (DOP) der Landesverwaltung und einigen Sekundärindikatoren.

*Abbildung 5: ALKIS Ausschnitt Sensenfeld, Bottrop*



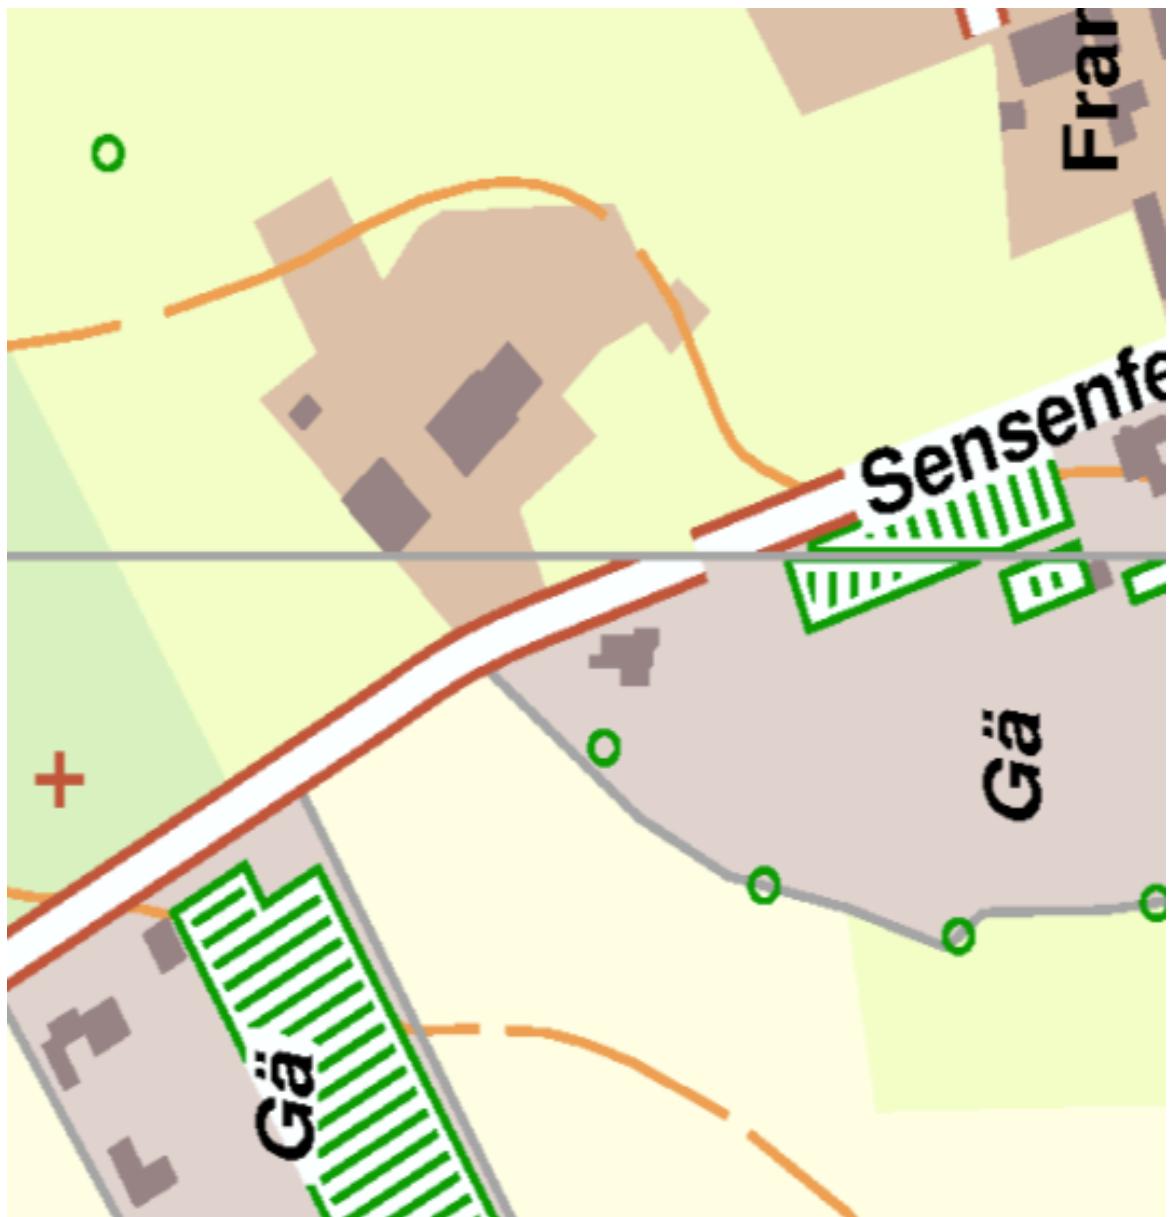
Quelle: eigene Abbildung mit Geobasis NRW (2023a).

Damit soll eine automatische Ableitung der Landbedeckung des Landes erfolgen. Darüber hinaus sollen die Ergebnisse zur Fortführung der Datenbestände in den Fachverfahren des amtlichen topografisch-kartographischen Informationssystems (ATKIS), sowie dem amtlichen Liegenschaftskatasterinformationssystems (ALKIS), genutzt werden (ebd.).

Das ALKIS ist das Fachverfahren, in dessen Rahmen das Liegenschaftskataster und die Flurkarte einer Stadt laufend geführt werden (Abb. 5). Im Rahmen des ATKIS wird die Oberflä-

che des jeweiligen Gebiets betrachtet und mit bestimmten Datenprodukten wie dem Digitalen Landschaftsmodell, dem digitalen Geländemodell (DGM) oder der digitalen topographischen Karte beschrieben (AdV 2024).

Abbildung 6: ATKIS digitale topographische Karte Ausschnitt Sensenfeld, Bottrop



Quelle: eigene Abbildung mit Geobasis NRW (2023c).

Ein DOP entsteht bei einer Luftbildbefliegung einer Fläche. In einem regelmäßigen Turnus (ein- oder zweijährig) werden Unternehmen durch das Landesvermessungsamt, sowie die Katasterämter der jeweiligen Städte, beauftragt, Fotos der jeweiligen Gebietskörperschaft aus der Luft zu machen. Die beauftragten Unternehmen können dabei hochauflöste Bilder erzielen.

Abbildung 7: DOP NRW Maßstab 1:870000



Quelle: eigene Abbildung mit Geobasis NRW (2023b).

Die in den Cop4ALL Prozess hineinfließenden DOP liefern eine geometrische Auflösung von einem 0,01 Quadratmeter pro Pixel (Sandmann et al. 2022: 302).

Damit sind die DOP aus Abbildung 7 und 8 10.000-mal genauer als die Copernicus-Daten des Sentinel 2 Programms aus Abbildung 9: ein Pixel eines Bildes von Sentinel 2 deckt dabei eine Fläche von 100 Quadratmetern ab, mit einer Aktualisierungsrate von mindestens fünf Tagen (ebd.; Malenovský et al. 2012: 95, Eftas 2019).

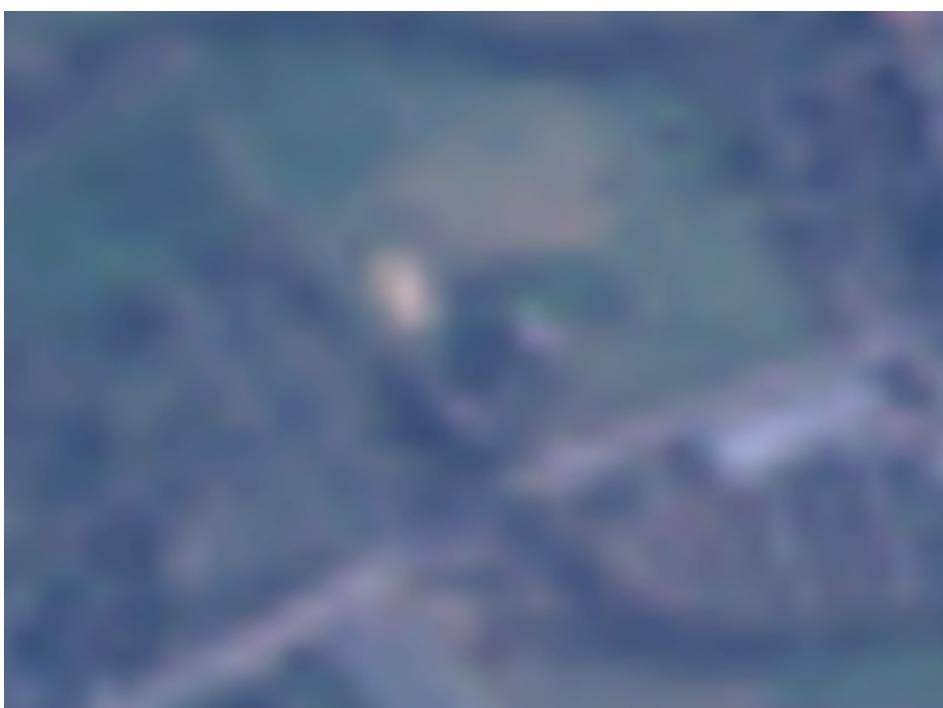
Da die Fortführung der Datenbestände des ALKIS und ATKIS eine Kernaufgabe der Vermessungsverwaltung darstellt, ist die Einbeziehung von hochfrequenten Daten im Gegensatz zu den allerhöchstens jährlich stattfindenden Luftbildbefliegungen eine sinnvolle Unterstützung, um Änderungen im Datenbestand zu detektieren (Sandmann et al. 2022: 300ff.).

Abbildung 8: DOP Ausschnitt Sensenfeld, Bottrop Maßstab 1:1700



Quelle: ebd.

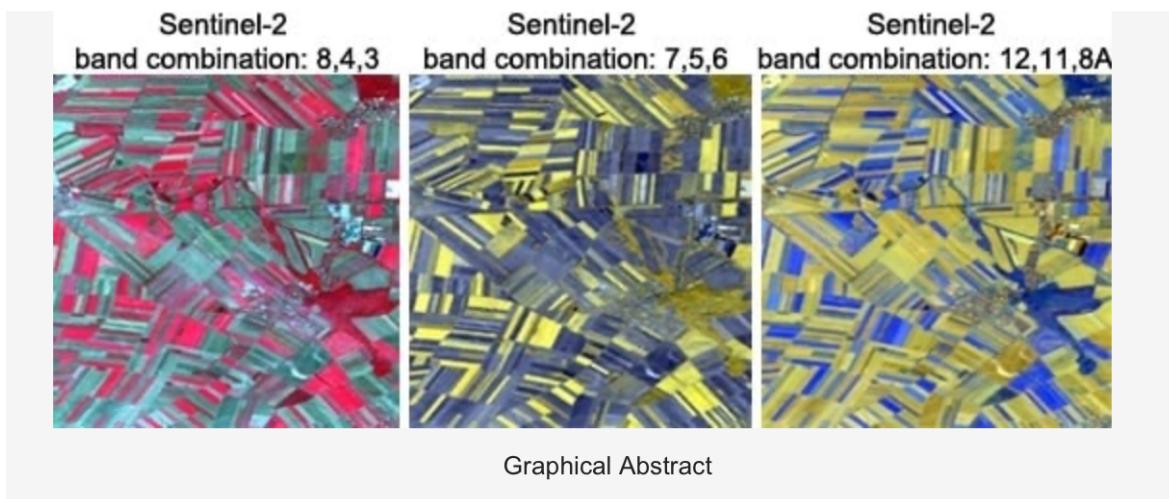
Abbildung 9: Sentinel-2 Bild Ausschnitt Sensenfeld, Bottrop



Quelle: eigene Abbildung +40% Helligkeit mit CODE-DE (2024a).

Hinter den innerhalb dieses Prozesses verwendeten Copernicus-Daten (Abb. 9) verbergen sich maßgeblich die Fernerkundungsdaten der Zwillingssatelliten Sentinel-2A und Sentinel-2B, die 2015 und 2017 von der Europäischen Weltraumorganisation in den Erdorbit gebracht worden sind (ESA 2014; Phiri et al. 2020: 2291f.; Immitzer et al. 2016: 166ff.).

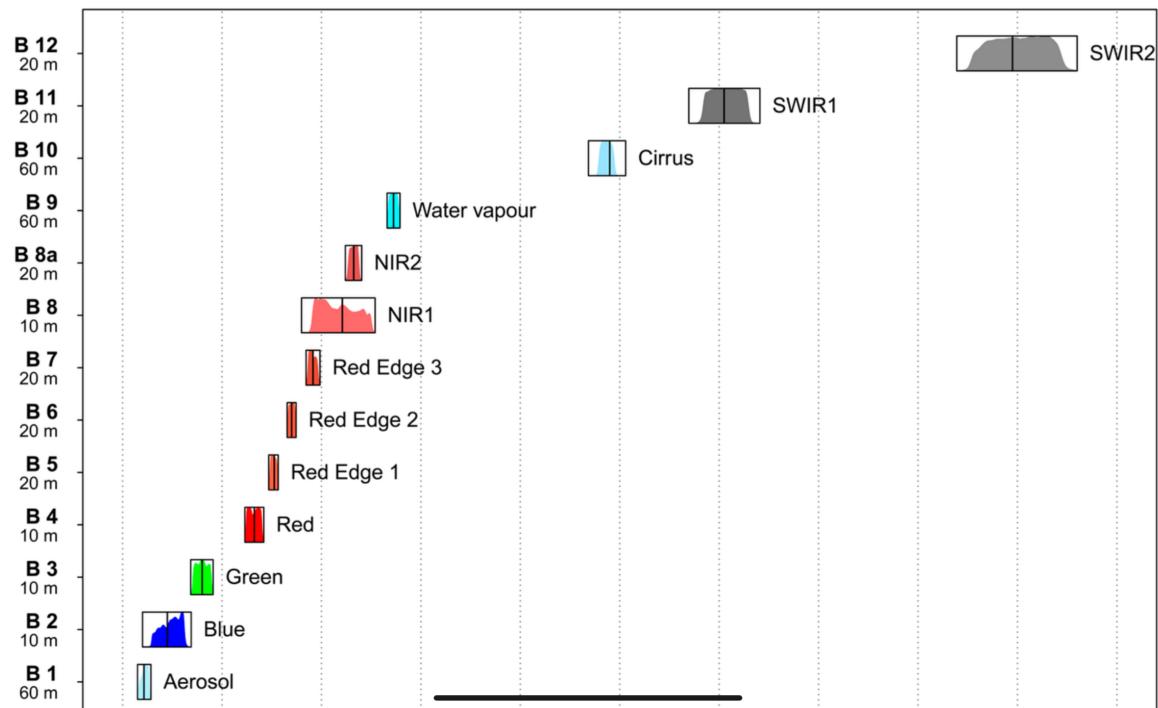
*Abbildung 10: Kombination unterschiedlicher multispektralen Bänder*



Quelle: Immitzer et al. 2016: 166.

Sinn und Zweck dieser Satelliten ist es mit Hilfe von multispektralen Bildgebungsinstrumenten zeitlich hochauflöste Satellitenbilder zu erstellen, um damit den Zustand der Landoberfläche zu beobachten und langfristig mittels Zeitreihendaten zu beurteilen (ebd.).

*Abbildung 11: 13 Multispektrale Bänder von Sentinel-2*



Quelle: Immitzer et al. 2016: 170.

Mithilfe der unterschiedlichen multispektralen Kanäle der Satelliten lassen sich mehr als nur optische Daten aus den Bildern ableiten: über eine bestimmte Kombination von einigen der 13 multispektralen Kanäle lassen sich unterschiedliche Pflanzenarten oder ihr Zustand ableiten (Immitzer et al. 2016: 166ff.).

Abbildung 12: *Sentinel Bild NDVI Ausschnitt Sensenfeld (im roten Kreis), Bottrop*



Quelle: eigene Abbildung mit CODE-DE (2024b).

Durch eine Kombination der Bänder B8 und B4 der Satelliten lässt sich die Fotosynthese-Kapazität von Pflanzen ableiten (Tucker/Sellers 1986: 1408,1414). Je grüner eine Fläche ist, desto produktiver ist sie (ebd.; vgl. Abb. 12). Bei der Untersuchung jedes einzelnen Pixels lässt sich anhand des Farbwertes eine Information gewinnen, aus der der Normalized Differenced Vegetation Index (NDVI) gewonnen wird. Daher lassen sich anhand dieser Bilder trotz der niedrigen geometrischen Auflösung versiegelte Flächen von vegetativen Flächen unterscheiden (Weng 2012: 34ff.). Der NDVI-Wert ist einer der in Cop4ALL einfließenden Sekundärindikatoren.

## 3.2 Ist Prozess

### 3.2.1 Funktionsweise und Ergebniserzeugung

Die grundsätzliche Funktionsweise von Cop4ALL basiert auf der Klassifikation von Fernerkundungsdaten als Eingangsdaten, um die Landbedeckung mit Hilfe von KI-Verfahren abzuleiten (Sandmann et al. 2022: 301ff.). Weitere Eingangsdaten sind die ALKIS Bestandsdaten für das automatisierte Trainieren der NN oder das normalisierte Digitale Oberflächenmodell (nDOM), das als Differenz zwischen dem DGM und dem digitalen Oberflächenmodell (DOM) gebildet wird, um die relative Höhe einzelner Objekte zu identifizieren (ebd.; Stolz 2013: 148f.).

*Abbildung 13: Cop4ALL Landbedeckung Sensenfeld, Bottrop*



Quelle: eigene Abbildung mit Geobasis NRW (2022/2023).

Das Ergebnis des Verfahrens ist die Einteilung der Landbedeckung in eine von 15 Objekt-, Attribut- oder Wertearten. Diese wurden das erste Mal zum Stichtag 1. April 2022 für NRW abgeleitet (Sandmann et al. 2022: 303ff.; vgl. Abb. 13).

Dabei wurden sodann die ermittelten Landbedeckungsklassen mit Validierungsdaten des Kreis Kleve verglichen (Sandmann et al. 2022: 306f.). Hierzu wurden 1588 Validierungspunkten in Kenntnis über die wahre Landbedeckungsklasse verteilt. Dabei lässt sich für die Landbedeckungsklassifikation von Cop4ALL eine Gesamtgenauigkeit von 87,8% für das betrachtete Gebiet feststellen. Die Klassen Hoch- und Tiefbau, fließende und stehende Binnengewässer, sowie Gras, Getreide, Laub- und Nadelbaum lassen sich nach Sandmann et al. gut voneinander trennen (ebd.). Meer, Eis, Festgestein und Röhricht/Schilf kommen

im Kreis Kleve nicht vor. Die Klassen Lockermaterial, Gehölz und Büsche sind für den Prozess schwieriger zu klassifizieren, da es sich hierbei um Mischflächen, bestehend aus Geröll, Sand, Schotter und Abfall handelt, sowie im Falle von Gehölz und Büschen um ungenaue räumliche Definitionen (ebd.).

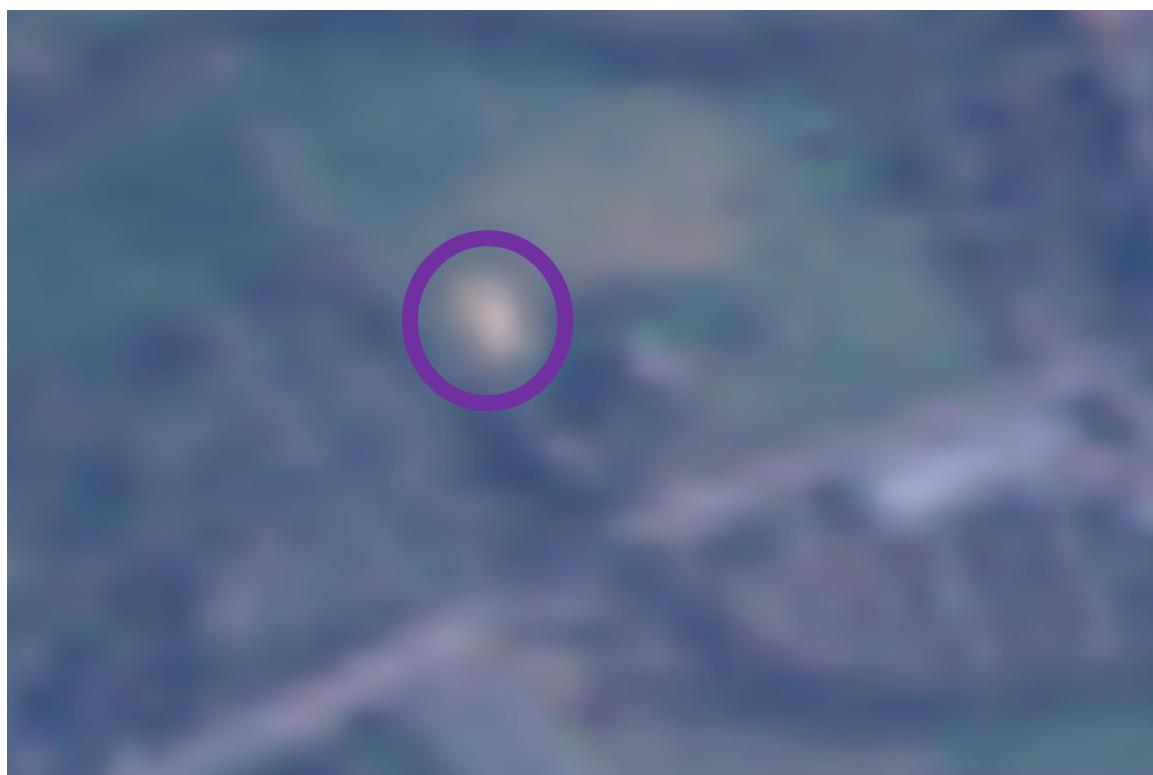
*Abbildung 14: Vergleich zwischen Cop4ALL und DOP Ausschnitt Sensenfeld, Bottrop*



Quelle: eigene Abbildung mit Geobasis NRW (2022/2023) / Geobasis NRW (2023c).

Obwohl das ALKIS in Abbildung 5 ersichtlich die Information über den bestehenden Reitplatz liefert, erzeugt Cop4ALL für den Reitplatz in Abbildung 14 die drei Landbedeckungsklassen Gras, Getreide und Tiefbau.

*Abbildung 15: Sentinel-2 Bild Reitplatz (im lila Kreis) Ausschnitt Sensenfeld, Bottrop*



Quelle: eigene Abbildung +40% Helligkeit mit CODE-DE (2024a).

Dabei liegt die Quote dafür, dass, sobald eine Landbedeckungsklasse erkannt wurde, diese auch zu der echten Landbedeckungsklasse gehört (Nutzergenauigkeit), bei 85,2% für Getreide, 82,9% für Tiefbau und 90,7% für Gras (Sandmann et al. 2022: 306). Bei Ansicht eines Sentinel 2 Bildes wird auch deutlich, dass der Reitplatz klar zu erkennen ist und sich von anderen Geometrien abgrenzen lässt, insbesondere vor dem Hintergrund, dass der Reitplatz 712,5 Quadratmeter groß ist, irritiert das Ergebnis von einer dreifachen Landbedeckungsklassifizierung. Gleichermaßen wie das Ergebnis des nicht unerheblich großen Reitplatzes als (teilweise) versiegelte Fläche in Form der Landbedeckungsklassifizierung Tiefbau. Hierbei wird deutlich, dass die rein automatisierte Generierung von Trainingsdaten nicht ausreichend ist.

### 3.2.2 Verfahren

Für die Pixelklassifikation der Fernerkundungsdaten ist es notwendig einen Klassifikator zu trainieren (Sandmann et al. 2022: 302ff.; Eftas 2019: 3). Diese Trainingsdaten werden automatisiert aus dem ALKIS erzeugt und mit weiteren Sekundärindikatoren angereichert. Ein Sekundärindikator aus einem Satellitenbild könnte der NDVI sein.

*Abbildung 16: Rote Punkte = versiegelte Flächen*



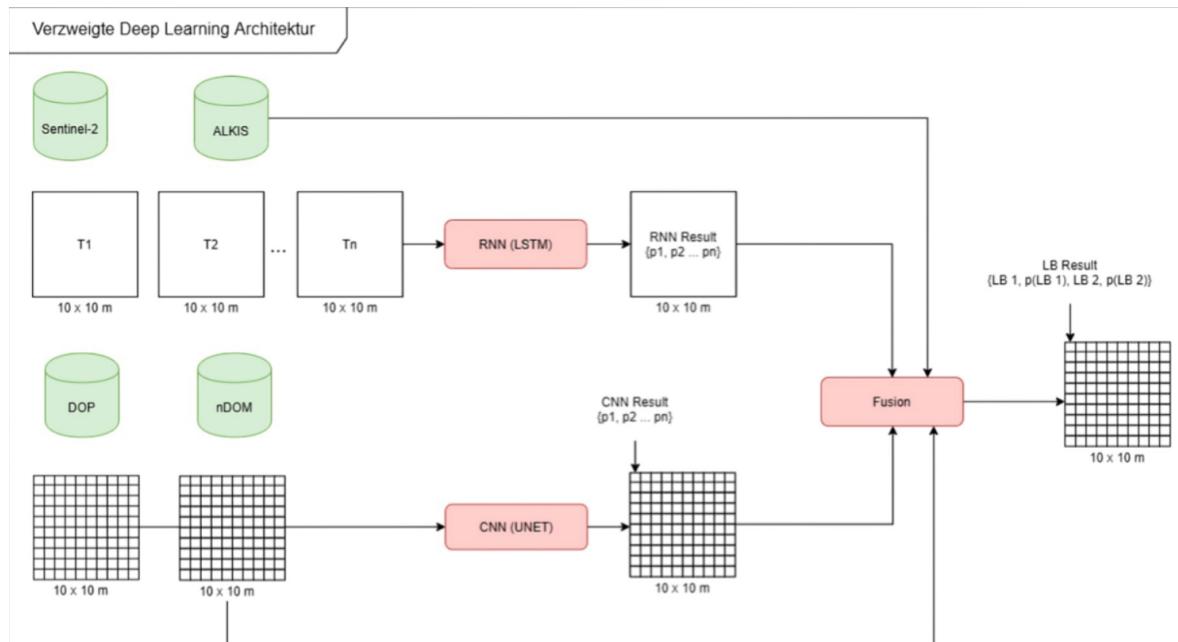
Quelle: Eftas 2019: 3.

Sekundärindikatoren aus dem DOP können das nDOM und das DGM sein (ebd.). Dabei erfolgt die Auswahl der Trainingsdaten für jedes zu klassifizierende Gebiet individuell durch Referenzpunkte (Abb. 16), wie z.B. beim Training der Landbedeckungsklasse „LB\_Tiefbau“. Diese wird aus den ALKIS Bestandsobjektarten „AX\_Platz, Funktion = Parkplatz“ und „AX\_Straßenverkher“ trainiert. Die Landbedeckungsklasse „Hochbau“ wird mit „AX\_Gebäude“ trainiert.

Daraufhin folgt die Bildanalyse durch die verzweigte Deep-Learning-Architektur, bei der die Sentinel 2 Daten für die zeitliche Aktualität der Landbedeckung sorgen und die DOP für die geometrische Auflösung (Sandmann et al. 2022: 302). Dazu werden die Bilder in thematische Raster überführt, bei denen jedes Pixel der verschiedenen Bilder nach einem Multi-Label-Prinzip klassifiziert wird. Die höchste Wahrscheinlichkeit entscheidet über die Zuordnung zur Klasse (ebd.: 303).

Die unterschiedlichen räumlichen sowie temporalen Auflösungen sorgen dafür, dass verschiedene NN zur Klassifikation verwendet werden müssen (ebd.). Das Recurrent Neural Network (RNN) wird für die Bilder der Sentinel 2 Satelliten genutzt (ebd.), da diese Art von NN effizient Zeitreihendaten verarbeiten kann (Fang et al. 2021: 97; Shertinsky 2020: 2f.). Die DOP werden unter der Beachtung eines nDOM mittels eines vortrainierten Convolutional Neural Network (CNN) klassifiziert (Sandmann et al. 2022: 303).

*Abbildung 17: Verzweigte DL-Architektur*



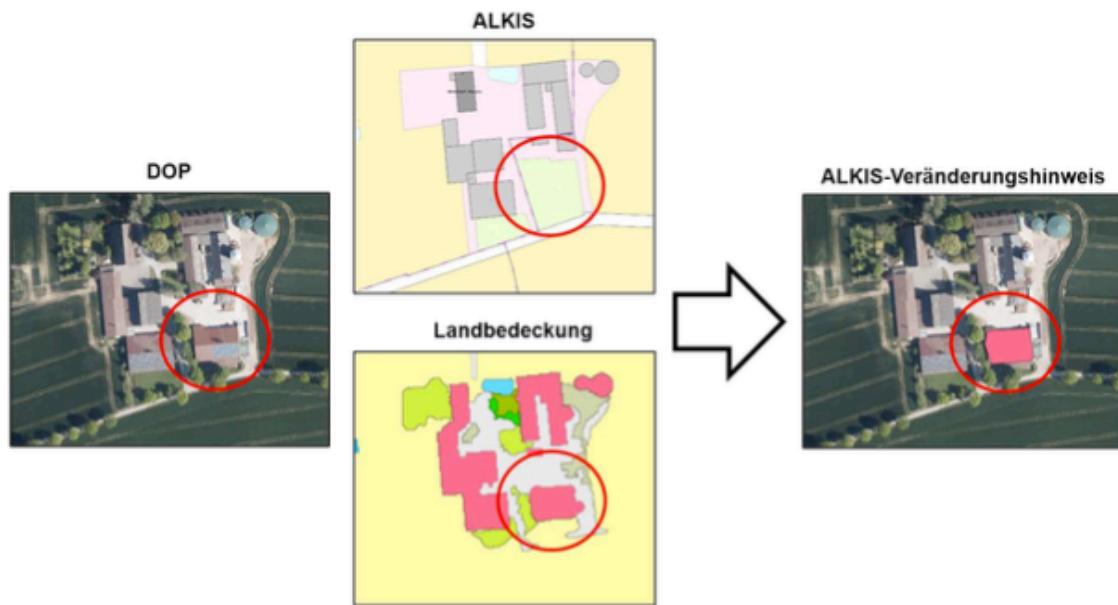
Quelle: Sandmann et al. 2022: 303.

Insbesondere im Zusammenhang mit der Binnendifferenzierung innerhalb der Landbedeckungsklassen der holzigen Vegetation ermöglicht dieser Schritt die Abgrenzung zwischen den Bäumen und Büschen sowie Sträuchern.

Dabei werden Punkte aus dem nDOM, die höher als fünf Meter liegen, den Bäumen zugeordnet, während darunterliegende Punkte als Büsche und Sträucher klassifiziert werden (ebd.: 304). Innerhalb der Datenfusion werden die Ergebnisse aus beiden Klassifikationszyklen zu einem Gesamtergebnis zusammengeführt.

Die Ergebnisse mehrerer, zeitlich hintereinanderliegender, Cop4ALL Landbedeckungsklassifizierungen lassen sich miteinander vergleichen (ebd.: 306f.). Dadurch lassen sich vergangene Änderungen in der realen Welt feststellen, die noch nicht vom Datenbestand erfasst sind.

*Abbildung 18: ALKIS Veränderungshinweis*



Quelle: Sandmann et al. 2022: 307.

In Abbildung 18 wurde durch die Klassifizierung ein Neubau entdeckt, der bereits im DOP ersichtlich ist. Allerdings fehlt bislang die Änderung im ALKIS Datenbestand. Daher erzeugt Cop4ALL einen ALKIS-Veränderungshinweis für diesen Bereich. Die Wahrscheinlichkeit für die Detektion einer echten Änderung liegt in 2022 bei 10%, wenn gleich die Validität der Änderungsdetektion bei 95% liegt (ebd.: 308).

### 3.3 Soll Prozess

Der Soll Prozess hat das Ziel, die Detektion der ALKIS Veränderungen von in 2022 10 % zu erhöhen bei einer mindestens gleichbleibend geeigneten Validität für die Fortführung des ALKIS. Dazu ist es erforderlich, die Qualität der Landbedeckungsklassifizierung innerhalb der aufeinanderfolgenden Landbedeckungsklassifizierungszyklen zu erhöhen. Denn nur wenn die Realität richtig erkannt wird, kann auch eine richtige Änderung abgeleitet werden. 82,9% der Zuordnungen zur Landbedeckungsklasse Tiefbau sind in der Realität der Tiefbauklasse zu zuordnen (Sandmann et al. 2022: 306). Diese Klasse umfasst versiegelte Flächen mit ebenerdigen Bauwerken, die an der Oberfläche zu sehen sind (ebd.: 304). Diese relativ niedrige Quote kann damit zu tun haben, dass die versiegelten Flächen durch Vegetation überdeckt sind. Der zu klassifizierende Pixel ist sodann durch eine Baumkrone abgeschirmt (ebd.).

Abbildung 19: 2D Cop4ALL vs. 3D Real Mesh Ausschnitt Sensenfeld, Bottrop



Quelle: eigene Abbildung mit Cesium Ion (2024)/Geobasis NRW (2022/2023)

---

Der Algorithmus klassifiziert in einem derart gelagerten Sachverhalt richtig, denn der zu analysierende Pixel, der sich im zweidimensionalen Raum befindet, ist Vegetation. Erst das Verständnis darüber, dass Punkte in einem zweidimensionalen Raum mit derselben X- und Y-Koordinate nicht immer denselben Z-Wert tragen, kann diesem Umstand begegnen.

Durch die Zuhilfenahme von menschlichem Expertenwissen könnte eine bestimmte Konsellation, im Fall einer vermeintlich unrichtigen Klassifizierung, da Tiefbau Pixel von Vegetation verschattet werden könnten, vorgelegt und korrigiert werden.

Hierzu könnten Technologien der humanzentrierten KI für das Training des Klassifikators angewendet werden (Wirth et al. 2022: 82ff.). Aktives Lernen mit Zugehörigkeitsabfragen (ebd.: 88; Wang et al. 2015: 426f., 432f.) kann hierbei dazu dienen den Trainingsdatensatz zu verfeinern, indem unter bestimmten Voraussetzungen ein Experte nach seiner Einschätzung zu der Landbedeckungsklasse eines Pixels befragt wird. Diese Einschätzung wird so dann für die Klassifizierung übernommen (Wirth et al. 2022: 87ff.). Dieser iterative Prozess kann dazu führen, dass der Algorithmus in Zukunft in der Lage wäre, auch ohne das zusätzliche dreidimensionale Wissen über mehrere Z-Koordinaten an derselben X- und Y-Koordinate wohlmöglich die richtige Entscheidung zu treffen, indem vergleichbare Stellen erkannt und gleich eingeschätzt werden.

Dazu müssten Fälle zur Entscheidung vorgelegt werden, in der der Klassifizierungsmechanismus nach dem Multi-Label Prinzip während der Bildanalyse eine annährend unumstößlich hohe Annahme für eine krautige oder holzige Vegetationsklassifizierung trifft, die sich in unmittelbare Nähe zu versiegelten Flächen befindet. Diese Fälle könnten einem Domänenexperten (Dellermann et al. 2019b: 278) vorgelegt werden und dieser entscheidet autonom, aber in der Betrachtung des Gesamtsystems interaktiv, kooperativ und im Ergebnis hybrid, darüber, wie die Realität an der jeweiligen Stelle ist.

Im Anschluss an eine näher zu bestimmende Anzahl von Entscheidungen eines Domänenexperten könnte der Klassifikator mit dem neuen Trainingsdatensatz trainiert werden. So könnte durch das SE die Zahl von 82,9% an richtig erkannten Tiefbau-Landbedeckungsklassen über das Gebiet einer gesamten Stadt erhöht werden. Zumindest aber in der Szene von Abbildung 19 würde sich so eine Verbesserung zum Status Quo zeigen.

Durch einen feineren und präziseren Trainingsdatensatz könnten so auch besser Änderungen im Gebiet detektiert werden, da die Realität präziser abgebildet wird.

Abbildung 20: 2D Cop4ALL vs. 3D Real Mesh Ausschnitt Legrandallee, Essen



Quelle: eigene Abbildung mit Cesium Ion (2024)/Geobasis NRW (2022/2023)

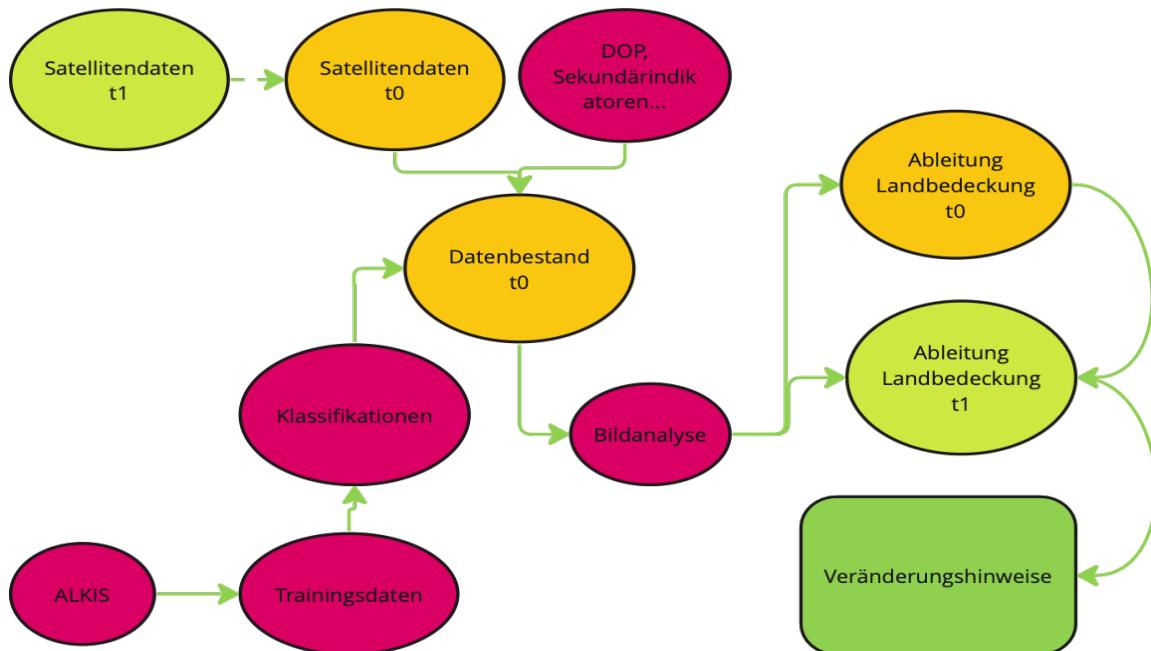
In Abbildung 19 würde der menschliche Experte sodann bestätigen, dass es sich im roten Beispiel um eine Vegetations-Klasse handelt. Im gelben Beispiel wird allerdings eine Tiefbau-Klasse durch eine holzige Vegetations-Klasse verschattet. Auch Abbildung 20 zeigt eine ähnliche Konstellation, in der auf einer Allee Tiefbau von Vegetation verschattet wird. Sofern dieser Umstand unkorrigiert bliebe, würde ein ALKIS-Veränderungshinweis erzeugt werden, sobald der Baum an der Stelle gerodet werden würde, da nun in der nächsten Ableitung eine Tiefbauklassifizierung an einer Stelle auftreten würde, an der vorher Vegetation war. Dabei ist die betreffende Stelle in der Realität die ganze Zeit versiegelt gewesen.

## 4 Fazit

Fraglich bleibt, ob der Soll Prozess ein Beispiel für das Aufkeimen von HI sein kann.

*Abbildung 21: Prozess ohne HI*

### Prozess vorher

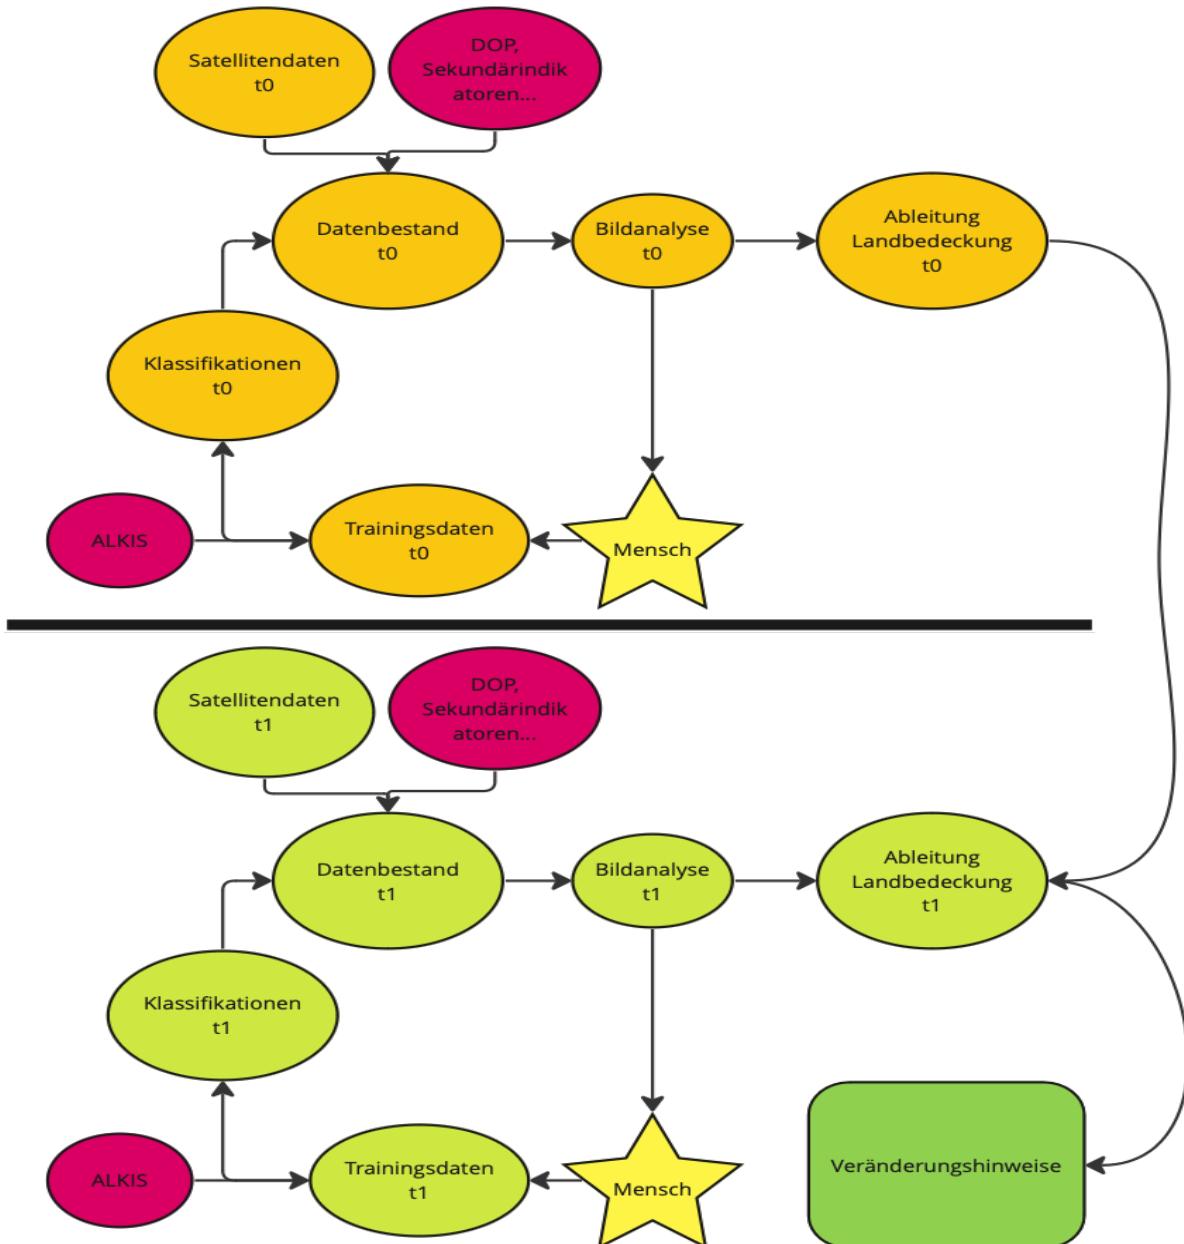


Quelle: eigene Abbildung in Anlehnung an Sandmann et al. 2022: 303.

Im Soll Prozess wird ein komplexes Ziel verfolgt: die Steigerung der Detektionsqoute von ALKIS Veränderungshinweisen bei einer gleichermaßen hohen Qualität der Hinweise. Dazu muss die zugrundeliegende Datenbasis die Realität gut beschreiben, denn nur so sind Veränderungshinweise auch geeignet, das ALKIS fortzuführen.

Abbildung 22: Prozess mit HI

## Prozess nachher



Quelle: eigene Abbildung in Anlehnung an Sandmann et al. 2022: 303.

Sobald ein Änderungshinweis erzeugt wird, der auf einer falschen Landbedeckungs-Annahme beruht, ist der Veränderungshinweis für die Fortführung des ALKIS praktisch unbrauchbar. Durch menschliche Intelligenz im Feedbackzirkel von KI (Dellermann et al.: 2019a: 639ff.) wird der Prozess des ausschließlich automatisierten Trainings der Klassifikatoren aufgebrochen und regelbasiert ein menschlicher Experte nach seiner Einschätzung in der Bildanalyse befragt. Der Trainingsdatensatz müsste sodann mit den menschlichen Entscheidungen in der Bildanalyse als Goldstandard übernommen werden.

Dieser Umstand allein führt noch nicht zu HI, denn das SE wird nur einseitig in Form eines verbesserten maschinellen Outputs geschult (ebd.). Für HI ist es jedoch erforderlich, dass beide Parteien des SE kontinuierlich voneinander lernen und gemeinsam einen Output erzeugen, der ohne die Fähigkeiten und das Wissen der anderen Komponente nicht möglich gewesen wäre (ebd.). Sobald jedoch ein höherer Grad an validen Veränderungshinweise erkannt und erzeugt wird, die der Mensch noch nicht in seinem Datenbestand übernommen hat und diese gleichsam für die Fortführung des ALKIS Datenbestandes verwendet werden können, lernt ebenfalls der Mensch von der Maschine. Da stetig Daten in Form von neuen Fotos durch die Satelliten erzeugt werden, ist eine kollektive, kontinuierliche Steigerung an Wissen innerhalb des SE gegeben. Damit entstünde taxonomisch und theoretisch (vgl. Abb. 22, 23) im Sollprozess HI.

Abbildung 23: Taxonomie-HI



Quelle: eigene Abbildung in Anlehnung an Dellermann et al. 2019b: 278.

## 5 Quellenverzeichnis

AdV (2024): ATKIS und Liegenschaftskataster. Bei Onlinequelle: <https://www.adv-online.de/AdV-Produkte/Liegenschaftskataster/> (Abrufdatum: 08.03.24).

Buxmann, Peter/Schmidt, Holger (2021): Künstliche Intelligenz. 2. Auflage. Berlin, Heidelberg: Springer Gabler.

Carbonell, Jaime G./Michalski, Ryszard S./Mitchell, Tom M. (1997): An Overview of Machine Learning. In: Carbonell, Jaime G./Michalski, Ryszard S./Mitchell, Tom M. (Hrsg.): Symbolic Computation. S. 3-23. Berlin: Springer. [https://doi.org/10.1007/978-3-662-12405-5\\_1](https://doi.org/10.1007/978-3-662-12405-5_1).

CODE-DE (2024a): True Color Bild mit Sentinel-2 L1C vom 27.01.2024. Bei Onlinequelle: [https://browser.code-de.org/#lat=51.57659&lng=6.88817&zoom=16&time=2024-01-27&preset=1\\_TRUE\\_COLOR&datasource=Sentinel-2%20L1C](https://browser.code-de.org/#lat=51.57659&lng=6.88817&zoom=16&time=2024-01-27&preset=1_TRUE_COLOR&datasource=Sentinel-2%20L1C) (Abrufdatum: 09.03.24).

Cesium ion (2024): Cesium ion Stories mit Google Photorealistic 3D Tiles. Bei Onlinequelle: <https://ion.cesium.com/stories/viewer/?id=7507ba4e-27f1-4fe0-829c-03bfd730fc6b> (Abrufdatum: 14.03.24).

CODE-DE (2024b): NDVI Bild mit Sentinel-2 L1C vom 27.01.2024. Bein Onlinequelle: [https://browser.code-de.org/#lat=51.57659&lng=6.88817&zoom=16&time=2024-01-27&preset=3\\_NDVI&datasource=Sentinel-2%20L1C](https://browser.code-de.org/#lat=51.57659&lng=6.88817&zoom=16&time=2024-01-27&preset=3_NDVI&datasource=Sentinel-2%20L1C) (Abrufdatum: 09.03.24).

Dellermann, Dominik/Ebel, Phillip/Söllner, Matthias/Leimeister, Jan Marco (2019a): Hybrid Intelligence. In: Business & Information Systems Engineering, Volume 61. S. 637-643. <https://doi.org/10.1007/s12599-019-00595-2>.

Dellermann, Dominik/Calma, Adrian/Lipusch, Nikolaus/Weber, Thorsten/Weigel, Sascha/Ebel, Phillip (2019b): The Future of Human-AI Collaboration: A Taxonomy of Design Knowledge for Hybrid Intelligence Systems. In: Proceedings of the 52nd Hawaii International Conference on System Science. S. 274-283. <https://hdl.handle.net/10125/59468>.

Eftas Fernerkundung Technologietransfer GmbH (2019): COP4ALL in NRW. In: Newsletter für Geoinformation und IT Dienstleistung 2019 – Nr. 1. Bei Onlinequelle: <https://www.eftas.de/upload/31207765-ALBEDO-19-1-digital.pdf> (Abrufdatum: 08.03.24).

Ertel, Wolfgang (2021): Grundkurs Künstliche Intelligenz. 5. Auflage. Wiesbaden: Springer Vieweg.

- 
- ESA (2014): Sentinel-2 Mission Guide. Bei Onlinequelle: <https://sentinels.copernicus.eu/web/sentinel/missions/sentinel-2> (Abrufdatum: 08.03.24).
- Fang, Wei/Chen, Yupeng/Xue, Qiongying (2021): Survey on Research of RNN-Based Spatio-Temporal Sequence Prediction Algorithmus. In: Jounral on Big Data, Volume 3 (No. 3). S. 97-110. <https://doi.org/10.32604/jbd.2021.016993>.
- Franklin, Stand/Graesser, Art (1997): Is It an agent, or just a program?: A taxonomy for autonomous agents. In: Müller, Jörg P./Wooldridge, Michael J./Jennings, Nicholas R. (Hrsg.): Intelligent Agents III. Agent Theories, Architectures, and Languages. Volume 1193, S. 21-35. <https://doi.org/10.1007/BFb0013568>.
- Fridman, Lex/Lecun, Yann (2024): #416 Yann Lecun: Meta AI, Open Source, Limits of LLMs, AGI & the Future of AI. In: Lex Fridman Podcast, 1:50min – 2:20min. Bei Onlinequelle: <https://open.spotify.com/episode/0bXyQJAylGg7E5mZnyHhNb> (Abrufdatum: 25.03.24).
- Geobasis NRW (2023a): WMS NW ALKIS / Amtliche Basiskarte 1:5000, Liegenschaftskataster. Bei Onlinequelle: [https://www.tim-online.nrw.de/tim-online2/?bg=base-mapDE\\_grau&bbox=334520,5636973,366050,5656675&cen-ter=350285,5646824&wms=https://www.wms.nrw.de/geobasis/wms\\_nw\\_dop,nw\\_dop\\_rgb](https://www.tim-online.nrw.de/tim-online2/?bg=base-mapDE_grau&bbox=334520,5636973,366050,5656675&cen-ter=350285,5646824&wms=https://www.wms.nrw.de/geobasis/wms_nw_dop,nw_dop_rgb) (Abrufdatum: 27.03.24).
- Geobasis NRW (2023c): WMS NW DOP mit Overlay. Bei Onlinequelle: [https://www.tim-online.nrw.de/tim-online2/?bg=base-mapDE\\_grau&bbox=334520,5636973,366050,5656675&cen-ter=350285,5646824&wms=https://www.wms.nrw.de/geobasis/wms\\_nw\\_dop,nw\\_dop\\_rgb](https://www.tim-online.nrw.de/tim-online2/?bg=base-mapDE_grau&bbox=334520,5636973,366050,5656675&cen-ter=350285,5646824&wms=https://www.wms.nrw.de/geobasis/wms_nw_dop,nw_dop_rgb) (Abrufdatum: 27.03.24).
- Geobasis NRW (2023b): WMS NW DTK10. Bei Onlinequelle: <https://www.bezreg-koeln.nrw.de/geobasis-nrw/produkte-und-dienste/topographische-karten/aktuelle-topographische-karten/digitale> (Abrufdatum: 27.03.24).
- Geobasis NRW (2022/2023): WMS NW Landbedeckung. Bei Onlinequelle: <https://www.bezreg-koeln.nrw.de/geobasis-nrw/produkte-und-dienste/luftbild-und-satellitenbildinformationen/aktuelle-luftbild-und-3> (Abrufdatum: 27.03.24).

- 
- Goodfellow, Ian/Bengio, Yoshua/Courville, Aaron (2016): Deep Learning. Cambridge: MIT Press. Bei Onlinequelle: <https://www.deeplearningbook.org/contents/mlp.html> (Abrufdatum: 25.03.24).
- Immitzer, Markus/Vuolo, Francesco/Atzberger, Clement (2016): First Experience with Sentinel-2 Data for Crop and Trees Classification in Central Europe. In: Remote Sensing, Volume 8 (Issue 3). S. 166-193. <https://doi.org/10.3390/rs8030166>.
- Lucas, Christian/Rattmann, Stefan/Kullmann, Karl-Heinz/Sandmann, Stefan/Wiese, Klaus/Kurstedt, Ramona/Behr, Christian/Käher, Rene (2020): Landbedeckung und Landnutzung – Realisierung neuer Geobasisdatenprodukte. In: Zeitschrift für Geodäsie, Geoinformation und Landmanagement, Heft 1, 145 Jahrgang. S. 56-66. DOI 10.12902/zfv-0288-2019.
- Malenovský, Zbyněk/Rott, Helmut/Cihlar, Josef Cihlar/Schaepmann, Michael E./García-Santos, Glenda/Fernandes, Richard/Berger, Michael (2012): Sentinels for science: Potential of Sentinel-1, -2, and -3 missions for scientific observations of ocean, cryosphere, and land. In: Remote Sensing of Environment, Volume 120. S. 91-101. <https://doi.org/10.1016/j.rse.2011.09.026>.
- Mitchell, Tom (1997): Machine Learning. New York: McGraw-Hill.
- Phiri, Darius/Simwanda, Matamyo/Salekin, Serajis/R. Nyirenda, Vincent/Murayama, Yuji/Ranagalage, Manjula (2020): Sentinel-2 Data for Land Cover/Use Mapping: A Review. In: Remote Sensing, Volume 12 (Issue 14). S. 2291-2326. <https://doi.org/10.3390/rs12142291>.
- Rey, Günter Daniel/Beck, Fabian (2018): Neuronale Netze. Bei Onlinequelle: <http://www.neuronalesnetz.de/index.html> (Abrufdatum: 25.03.24).
- Rich, Elaine (1985): Artificial Intelligence and the Humanities. In: Computers and the Humanities. Volume 19. S. 117-122. <https://doi.org/10.1007/BF02259633>
- Rich, Elaine (1983): Artificial Intelligence. New York: McGraw-Hill.
- SAM (2023): Segment Anything Research by Meta AI (Hrsg.). Bei Onlinequelle: <https://segment-anything.com/demo> (Abrufdatum: 26.03.24).

- 
- Sandmann, Stefan/Hochgürtel, Gregor/Piroska, Ruben/Steffens, Christian (2022): Cop4ALL NRW – Ableitung der Landbedeckung in Nordrhein-Westfalen mit Fernerkundung und künstlicher Intelligenz. In: Zeitschrift für Geodäsie, Geoinformation und Landmanagement, Heft 5, 147 Jahrgang. S. 299-310. DOI 10.12902/zfv-0407-2022.
- Sherstinsky, Alex (2020): Fundamentals of Recurrent Neural Networks (RNN) and Long Short-Term Memory (LSTM) network. In: Physica D: Nonlinear Phenomena, Volume 404. S. 1-27. <https://doi.org/10.1016/j.physd.2019.132306>.
- Stolz, Matthias (2013): Digitale Oberflächenmodelle aus Bildkorrelation. S. 139-150. Bei Onlinequelle: <https://dvw.de/sites/default/files/landesverband/bayern/anhang/beitragskontext/2014/stolz.pdf> (Abrufdatum: 12.03.24).
- Tucker, Compton J./Sellers, Piers J. (1986): Satellite Remote sensing of primary production. In: International Journal of Remote Sensing, Volume 7 (No. 11). S. 1395-1416.
- Wenig, Qihao (2012): Remote sensing of impervious surfaces in the urban areas: Requirements, methods, and trends. In: Remote Sensing of Environment, Volume 117. S. 34-49. <https://doi.org/10.1016/j.rse.2011.02.030>.
- Wirth, Christian/Schmid, Ute/Voget, Stefan (2022): Humanzentrierte Künstliche Intelligenz: Erklärendes interaktives maschinelles Lernen für Effizienzsteigerung von Parametriaufgaben. In: Hartmann, Ernst A. (Hrsg.): Digitalisierung souverän gestalten II. S. 80-92. [https://doi.org/10.1007/978-3-662-64408-9\\_7](https://doi.org/10.1007/978-3-662-64408-9_7).

---

## Eidesstattliche Erklärung & Einwilligungserklärung Nutzung von Plagiatssoftware

Name: Bleske Studiengang: WiSe 2023/24 MPA

Vorname: Benjamin Mtk.-Nr.: 36104066

Geb.-Ort: Witten Geb.-Datum: 11.02.1997

Mir ist bekannt, dass bei meiner Arbeit eine Prüfung auf nicht kenntlich gemachte übernommene Textpassagen und sonstige Quellen stattfinden kann (vgl. u.a. § 16 Abs. 7 der Allgemeinen Bestimmungen für Fachprüfungsordnungen mit den Abschlüssen Bachelor und Master der Universität Kassel). Ich stimme zu, dass dafür gegebenenfalls ein Upload auf eine externe Datenbank des jeweiligen Software-Anbieters erfolgt und die Arbeit dafür auch gespeichert wird, sofern meine Arbeit dafür vorab ausreichend anonymisiert wird (i.d.R. genügt dafür die Entfernung des Deckblatts und der Unterschriftenseite). Ich stimme ebenfalls zu, dass zukünftig umgekehrt auch andere Arbeiten auf Plagiate aus meiner anonymisierten Arbeit überprüft werden.

Ich versichere hiermit, dass ich meine Hausarbeit, Die Anonymisierung von personenbezogenen Daten im Kontext von BIG DATA selbstständig und ohne fremde Hilfe angefertigt habe. Alle von anderen Autoren wörtlich oder sinngemäß übernommenen Stellen sind entsprechend gekennzeichnet.

Mir ist bewusst, dass bei einem Verstoß gegen obige Erklärung nicht nur die betreffende Prüfungsleistung mit der Note – 5,0 – gewertet wird, sondern auch eine Exmatrikulation erfolgen kann.

Der Prüfungsausschuss entscheidet im Einzelfall.

Bottrop, 29.03.2024

Benjamin Bleske, Bleske

Ort, Datum

Unterschrift